Acta de Definición de Alcance — Datawarehouse OAAF

Oct 6, 2026 · @Érica Bordón

Esta acta define el alcance del Datawarehouse de la Oficina de Análisis Antiterrorista de Fronteras (OAAF), organización ficticia del sector público, para el Trabajo Práctico individual de la cátedra (hito H1).

Campo	Detalle
Universidad	Universidad del Norte — Paraguay
Carrera	Ingeniería Informática — 8.º semestre
Cátedra	Datawarehouse (22891)
Docente	Lic. Walter Romero
Alumna	Érica Bordón
Hito	H1 — Lanzamiento y definición de alcance
Organización	OAAF (ficticia, dataset sintético)

1. Descripción de la organización

La OAAF es una oficina pública ficticia que analiza los movimientos migratorios en los puestos de control de Paraguay para detectar riesgos asociados a terrorismo y delitos transnacionales.

- **Rubro:** sector público — seguridad y control migratorio.
- **Tamaño:** unos 40 funcionarios: una sede central en Asunción con el área de análisis y equipos destacados en los puestos de control.
- **Estructura:** 8 puestos de control asociados, de tipo aéreo, terrestre y fluvial (por ejemplo, el aeropuerto de Luque, el Puente de la Amistad en Ciudad del Este y el puente San Roque González en Encarnación).
- **Relación con otras instituciones:** recibe de Migraciones los registros de cruce y de organismos nacionales e internacionales las alertas sobre documentos y personas.

- **Carácter:** organización **ficticia**. Los nombres de los puestos de control son reales y se usan solo como catálogo de referencia; todos los movimientos, personas y alertas son sintéticos.

2. Rol asumido y sponsor

La alumna asume el rol de **analista de datos** del área de análisis de la OAAF: diseña el modelo, construye el ETL y entrega el tablero.

- **Sponsor:** la jefatura de la OAAF, que asigna personal y equipos de inspección a los puestos y presenta informes trimestrales.
- **Usuarios clave:** los analistas de riesgo y los jefes de equipo de cada puesto de control.

3. Problema o necesidad de negocio

La OAAF no sabe dónde ni cuándo se concentran las alertas, ni cuántas terminan en un hallazgo real. Los registros de cruce, las alertas y los resultados de inspección están en sistemas separados y se cruzan a mano en planillas.

El Datawarehouse integra esas fuentes para mejorar tres decisiones:

1. **Asignación de personal:** reforzar los puestos y franjas horarias con más flujo y más alertas.
2. **Priorización de controles:** enfocar la inspección secundaria en los tipos de alerta y de documento con mayor tasa de confirmación.
3. **Seguimiento:** detectar patrones de viaje irregulares y permanencias que exceden el plazo autorizado.

Criterio ético del análisis: el riesgo se mide por alertas, estado del documento y patrones de conducta de viaje, nunca por la nacionalidad. La nacionalidad se usa solo como dimensión descriptiva del flujo migratorio. Las personas se identifican con un código seudónimo, sin nombres ni números de documento.

4. Preguntas de negocio

El DW debe responder siete preguntas, cada una ligada a un indicador medible y a las dimensiones por las que se analiza.

N.º	Pregunta de negocio	Indicador	Analizado por
P1	¿Qué puestos de control concentran el flujo migratorio por mes y sentido (entrada/salida)?	Cantidad de movimientos y % sobre el total nacional	Puesto, tiempo, sentido
P2	¿En qué puestos y franjas horarias se generan más alertas?	Alertas cada 10.000 movimientos	Puesto, franja horaria, tipo de alerta
P3	¿Qué tipos de alerta terminan con más frecuencia en inspección secundaria confirmada o rechazo de ingreso?	Tasa de confirmación % = alertas confirmadas / alertas emitidas	Tipo de alerta, puesto, tiempo
P4	¿Qué tipos de documento presentan más observaciones (extraviado, robado, adulterado, vencido)?	Documentos observados cada 10.000 movimientos	Tipo de documento, puesto, tiempo
P5	¿Cuántos viajeros muestran patrones de cruce frecuente en poco tiempo, y en qué puestos?	Viajeros con 6 o más cruces en 30 días, por puesto y mes	Viajero, puesto, tiempo
P6	¿Cuál es la permanencia promedio por motivo de viaje y categoría migratoria, y cuántas exceden el plazo autorizado?	Permanencia promedio (días); % de permanencias excedidas	Motivo, categoría migratoria, tiempo
P7	¿Cómo varía el flujo por región de origen y motivo de viaje a lo largo del año?	Movimientos por mes; variación % contra el mismo mes del año anterior	País/región de origen, motivo, tiempo

P3 y P4 cruzan la tabla de hechos de movimientos con la de alertas mediante dimensiones conformadas (tiempo, puesto, viajero), lo que permite aplicar el operador drill-across.

5. Fuentes de datos previstas

El proyecto usa tres fuentes heterogéneas en tres formatos distintos; la tabla de hechos principal tendrá unas **50.000 filas** (mínimo exigido: 5.000).

Fuente	Formato	Contenido	Origen	Volumen estimado
Registro de movimientos migratorios	CSV (exportación del sistema de control fronterizo)	Fecha y hora, puesto, sentido, código de viajero, nacionalidad, tipo de documento, motivo, categoría migratoria, medio de transporte, plazo autorizado	Sintético, generado con Python	≈ 50.000 movimientos
Alertas y resultados de inspección	JSON (servicio de alertas)	Alerta emitida, tipo, nivel, estado del documento, resultado de la inspección secundaria	Sintético, generado con Python	≈ 2.000 alertas
Catálogo de puestos de control	Planilla Excel (.xlsx)	Puesto, tipo (aéreo/terrestre/fluvial), ciudad, departamento, país limítrofe, dotación de personal	Nombres reales de puestos, datos operativos simulados	8 puestos

- **Periodo cubierto:** 24 meses, de octubre de 2024 a septiembre de 2026.
- **Grano previsto de la tabla de hechos principal:** una fila por movimiento migratorio (un viajero, en un puesto, en un sentido, en una fecha y hora).
- **Imperfecciones deliberadas:** nulos, duplicados, fechas en formatos mixtos, códigos de puesto huérfanos e inconsistencias de texto (por ejemplo, “CDE”, “Ciudad del Este”, “ ciudad del este ”), documentadas en el anexo del informe.
- **Datos personales:** no hay datos de personas reales. Los viajeros se identifican con un código seudónimo; no se generan nombres ni números de documento.

6. Alcance preliminar del modelo dimensional

Se prevé un esquema estrella con dos tablas de hechos que comparten dimensiones conformadas; el diagrama y el DDL se entregan en H2, el 27/10/2026.

Tabla	Tipo	Contenido principal
fact_movimiento_migratorio	Hechos (principal)	Cantidad, minutos de control, días de permanencia, días excedidos, indicador de alerta
fact_alerta	Hechos (secundaria)	Cantidad de alertas, indicador de inspección secundaria, indicador de confirmación, indicador de rechazo
dim_tiempo	Dimensión	Día, mes, trimestre, año, día de semana, franja horaria, feriados
dim_puesto_control	Dimensión	Puesto, tipo, ciudad, departamento, país limítrofe
dim_viajero	Dimensión — SCD tipo 2	Código seudónimo, rango etario, categoría migratoria (turista, residente temporal, residente permanente)
dim_pais	Dimensión	Nacionalidad, región, pertenencia a MERCOSUR
dim_documento	Dimensión	Tipo de documento y estado (vigente, vencido, extraviado, robado, adulterado)
dim_motivo	Dimensión	Turismo, negocios, tránsito, trabajo, estudio, residencia
dim_tipo_alerta	Dimensión	Tipo de alerta, nivel de riesgo, organismo emisor
dim_transporte	Dimensión	Aéreo, terrestre particular, ómnibus, fluvial, a pie

- **SCD tipo 2 en dim_viajero:** la categoría migratoria cambia con el tiempo (un turista pasa a residente temporal); conservar el historial permite calcular la permanencia excedida según la categoría vigente en cada cruce (P6).
- **SCD tipo 1 en dim_puesto_control:** las correcciones de ciudad o departamento reemplazan el valor anterior, porque son errores de carga.
- **Miembro no definido:** cada dimensión incluirá la fila sk = -1 para códigos huérfanos o nulos.
- **Stack:** DuckDB 1.5, ETL en Python 3.12 + pandas 2.2, consultas OLAP con GROUPING SETS/CUBE/ROLLUP, tablero en Power BI Desktop y repositorio Git.