Informe final — Datawarehouse OAAF

Nov 12, 2026 · @Érica Bordón

Universidad del Norte · Ingeniería Informática · 8.º semestre · Cátedra Datawarehouse (22891)

Datawarehouse para el análisis de riesgos en los movimientos migratorios de los puestos de control de Paraguay

Dato	Información
Organización	Oficina de Análisis Antiterrorista de Fronteras (OAAF), ficticia
Asignatura	Datawarehouse (22891)
Docente	Lic. Walter Romero
Estudiante	Érica Bordón
Tipo de trabajo	Trabajo Práctico individual: Datawarehouse de punta a punta
Herramientas	DuckDB 1.5, DBeaver, Python 3.12 y pandas, Power BI Desktop, Git
Repositorio	github.com/EricaBordon/datawarehouse-oaaf

Resumen ejecutivo

Se construyó un Datawarehouse completo para la OAAF, desde tres fuentes heterogéneas hasta un tablero interactivo. Integra 50.956 movimientos migratorios y 1.999 alertas de 8 puestos de control, entre octubre de 2024 y septiembre de 2026, y responde las siete preguntas de negocio del acta de alcance.

Componente	Resultado
Modelo dimensional	Constelación de 2 tablas de hechos y 8 dimensiones, 5 de ellas conformadas
ETL	51.636 filas leídas = 50.956 cargadas + 680 en cuarentena; 9 de 9 controles en OK

Componente	Resultado
Historial (SCD tipo 2)	372 viajeros con cambios de categoría migratoria conservados
Análisis OLAP	7 vistas SQL con CUBE, ROLLUP, GROUPING SETS y drill-across
Tablero	2 páginas en Power BI, 12 medidas DAX, mapa de puestos y filtro interactivo

Principales hallazgos:

- El Puente de la Amistad concentra el 27,0 % del flujo nacional.
- La madrugada registra 500 alertas cada 10.000 movimientos, contra 360 a 390 en el resto del día; en el puente de Encarnación llega a 759.
- Las alertas por documentos robados o extraviados se confirman en el 59,4 % de los casos; las de la lista de vigilancia nacional, solo en el 9,8 %.
- 515 viajeros cruzaron 6 o más veces en 30 días, 179 de ellos por el Puente de la Amistad.
- Solo exceden el plazo los turistas que vienen por turismo: el 3,3 %, con 55 días de exceso en promedio.

Estos resultados apoyan tres decisiones: reforzar el personal de madrugada en los pasos terrestres, priorizar la inspección secundaria de alertas documentales y seguir a los viajeros con patrones de cruce frecuente.

1. Contexto y problema de negocio

La OAAF es una oficina pública ficticia que analiza los movimientos migratorios de 8 puestos de control de Paraguay para detectar riesgos asociados a terrorismo y delitos transnacionales. Tiene unos 40 funcionarios: un área de análisis en Asunción y equipos en puestos aéreos, terrestres y fluviales. Los nombres de los puestos son reales y se usan solo como catálogo; los movimientos, las personas y las alertas son sintéticos.

Problema: los registros de cruce, las alertas y los resultados de inspección estaban en sistemas separados y se cruzaban a mano en planillas. La OAAF no sabía dónde ni cuándo se concentraban las alertas, ni cuántas terminaban en un hallazgo real.

Decisiones que el Datawarehouse apoya:

1. Asignación de personal por puesto y franja horaria.
2. Priorización de la inspección secundaria según el tipo de alerta.
3. Seguimiento de patrones de viaje irregulares y permanencias excedidas.

Rol asumido: analista de datos del área de análisis. **Sponsor:** la jefatura de la OAAF. **Usuarios:** los analistas de riesgo y los jefes de equipo de cada puesto.

2. Objetivos y preguntas de negocio

Objetivo general: diseñar, implementar y explotar un Datawarehouse dimensional que integre los movimientos migratorios, las alertas y el catálogo de puestos de la OAAF para apoyar sus decisiones operativas.

Objetivos específicos:

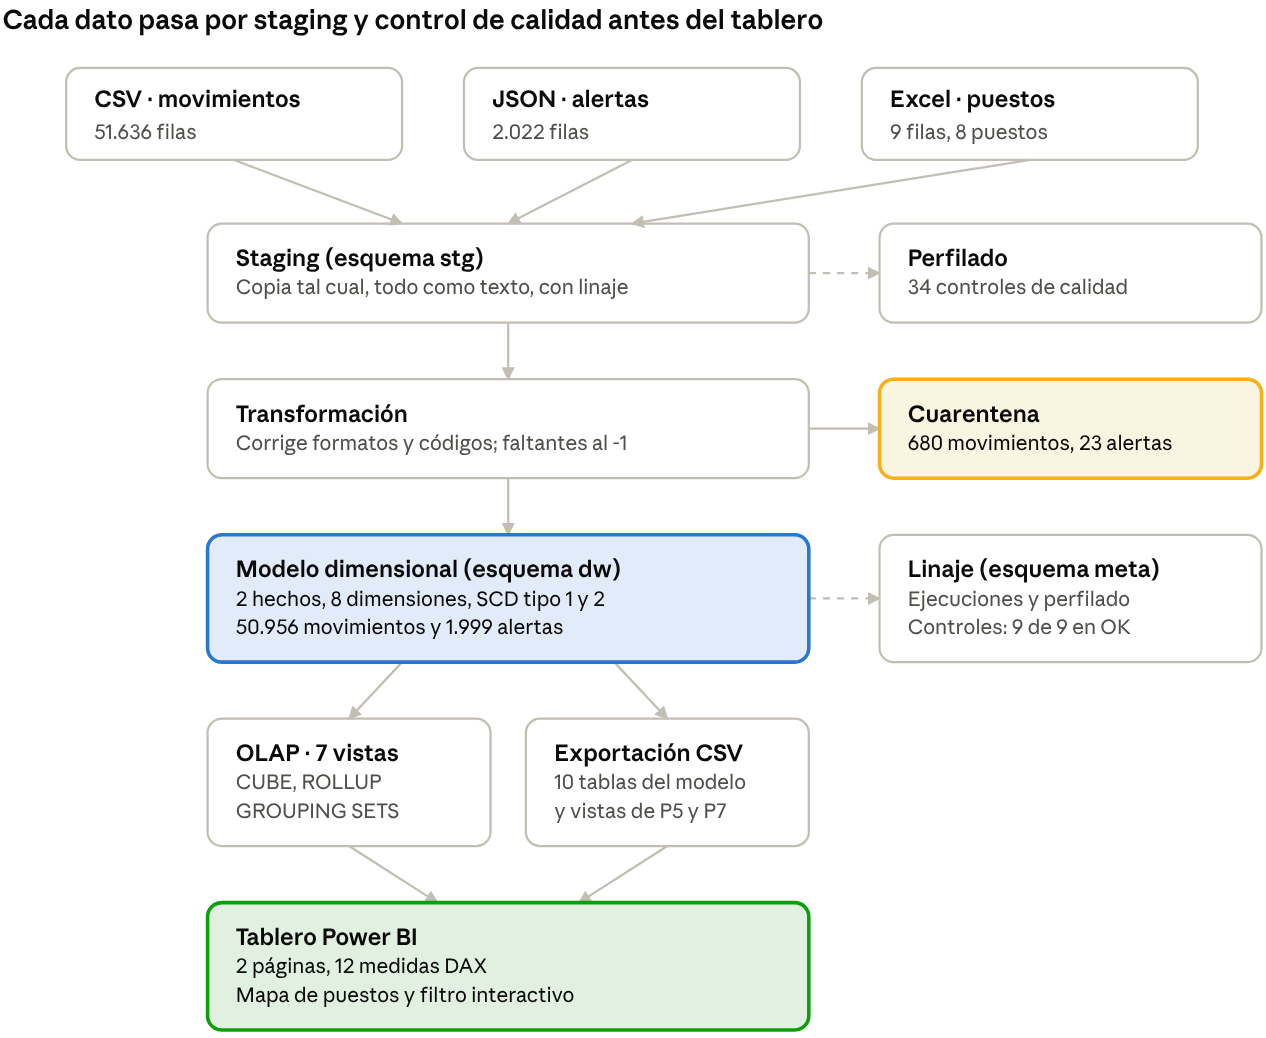
1. Generar un dataset sintético realista de tres fuentes heterogéneas, con defectos documentados.
2. Diseñar un modelo dimensional con dimensiones conformadas e historial de cambios.
3. Implementar un ETL trazable, con perfilado, cuarentena y controles de conciliación.
4. Responder las preguntas de negocio con operadores OLAP.
5. Comunicar los hallazgos en un tablero interactivo.

N.º	Pregunta	Indicador
P1	¿Qué puestos concentran el flujo migratorio por mes y sentido?	Movimientos y % sobre el total nacional
P2	¿En qué puestos y franjas horarias se generan más alertas?	Alertas cada 10.000 movimientos
P3	¿Qué tipos de alerta terminan con más frecuencia en confirmación o rechazo de ingreso?	Tasa de confirmación y de rechazo (%)
P4	¿Qué tipos de documento presentan más observaciones?	Documentos observados cada 10.000 movimientos
P5	¿Cuántos viajeros cruzan con mucha frecuencia y en qué puestos?	Viajeros con 6 o más cruces en 30 días
P6	¿Cuál es la permanencia promedio y cuántas exceden el plazo?	Permanencia promedio (días) y % de permanencias excedidas

N.º	Pregunta	Indicador
P7	¿Cómo varía el flujo por región de origen y motivo a lo largo del año?	Movimientos por mes y variación % interanual

3. Arquitectura de la solución

La solución corre completa en una computadora personal, sin servidores: DuckDB guarda el Datawarehouse en un solo archivo, DBeaver ejecuta los scripts SQL, Python genera los datos y orquesta el ETL, y Power BI presenta los resultados. La base tiene tres esquemas: `stg` para los datos crudos, `dw` para el modelo dimensional y `meta` para el linaje.



Arquitectura de la solución · de las fuentes al tablero

Los datos nunca pasan directo de la fuente al modelo: primero se reciben en staging, se perfilan y se limpian, y lo irrecuperable queda en cuarentena con su motivo.

4. Modelo dimensional

El modelo es una constelación: dos tablas de hechos que comparten cinco dimensiones conformadas. Esa estructura permite el drill-across entre movimientos y alertas que necesitan las preguntas P2, P3 y P4.

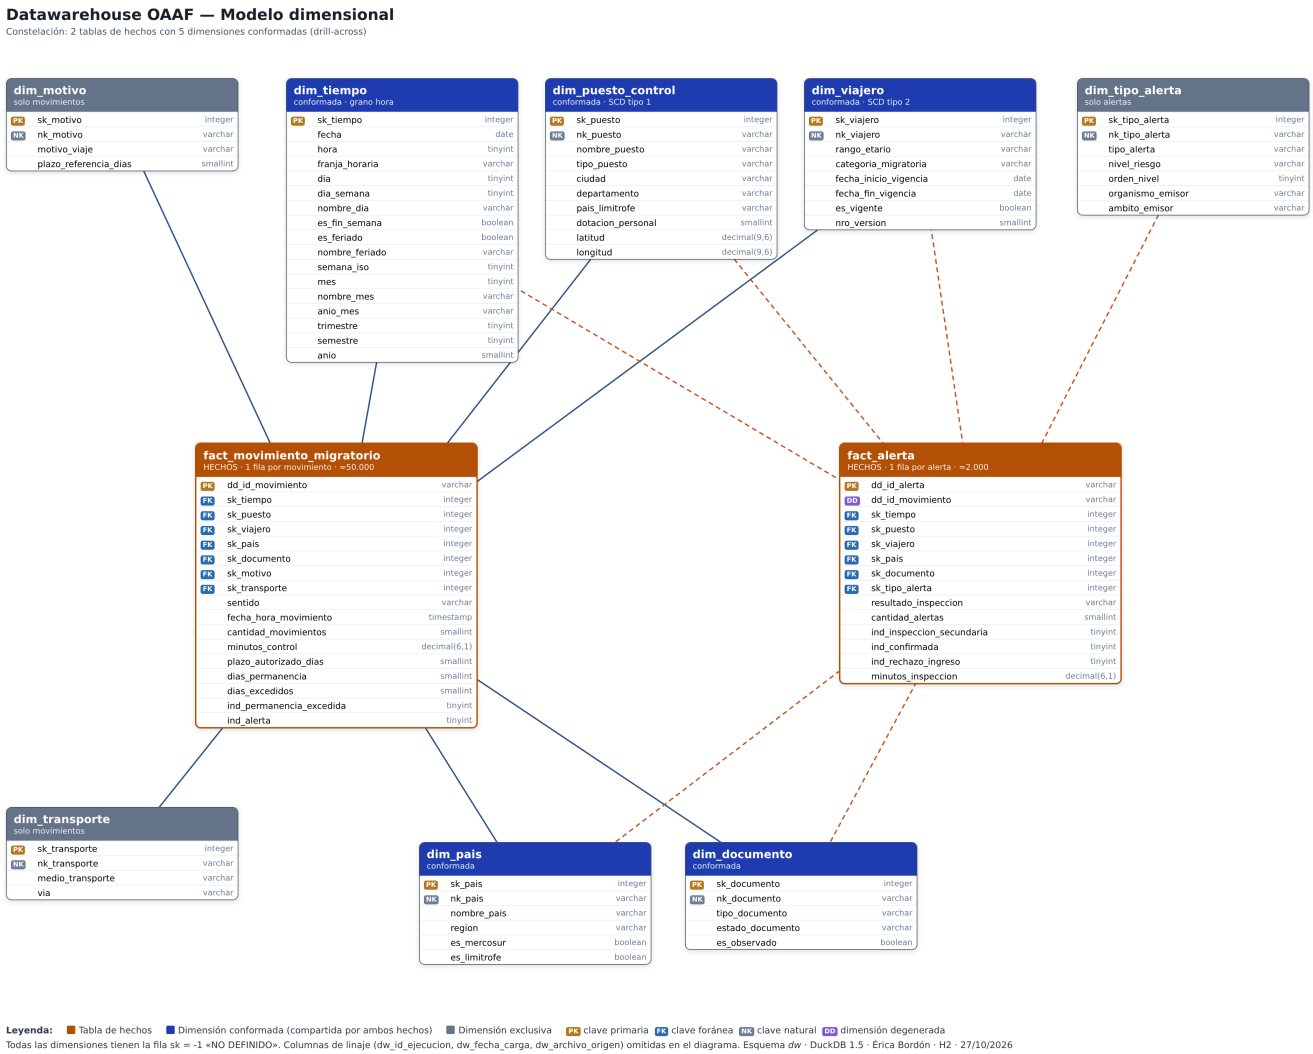


Figura 1. Modelo dimensional. Naranja: tablas de hechos; azul: dimensiones conformadas; gris: dimensiones exclusivas.

Tipo	Tabla	Contenido
Hechos	fact_movimiento_migratorio	Una fila por movimiento: un viajero, en un puesto, en un sentido, en una fecha y hora. Cantidad, minutos de control, plazo, días de permanencia, días excedidos e indicadores
Hechos	fact_alerta	Una fila por alerta emitida. Indicadores de inspección secundaria, confirmación y rechazo, y minutos de inspección
Conformada	dim_tiempo	Grano hora (clave AAAAMMDDHH), franja horaria, feriados de Paraguay, mes, trimestre, año
Conformada	dim_puesto_control	Puesto, tipo, ciudad, departamento, país limítrofe, dotación y coordenadas (SCD tipo 1)
Conformada	dim_viajero	Código seudónimo, rango etario y categoría migratoria con historial (SCD tipo 2)
Conformada	dim_pais	Nacionalidad, región, pertenencia a MERCOSUR
Conformada	dim_documento	Tipo y estado del documento
Exclusiva	dim_motivo, dim_transporte, dim_tipo_alerta	Motivo del viaje, medio de transporte y tipo de alerta con su nivel de riesgo

Decisiones de diseño:

- **dim_tiempo a nivel hora**, para analizar franjas horarias sin una dimensión aparte.
- **dim_viajero con SCD tipo 2:** cada cambio de categoría (turista, residente temporal, residente permanente) crea una versión con fechas de vigencia, y cada movimiento apunta a la versión vigente en su fecha. Así la permanencia excedida se mide según la categoría de cada cruce.
- **dim_puesto_control con SCD tipo 1:** las correcciones sobrescriben, porque son errores de carga.

- **Miembro "NO DEFINIDO" (sk = -1)** en todas las dimensiones: las claves foráneas de los hechos nunca quedan en NULL.
- **Linaje** en cada fila (`dw_id_ejecucion` , `dw_fecha_carga` , `dw_archivo_origen`) y registro de cada carga en `meta.ejecucion` .

El diccionario de datos completo, columna por columna, está en `docs/Matriz_Bus_y_Diccionario_DW_OAAF.xlsx` .

5. Proceso ETL y calidad de datos

El ETL tiene seis scripts SQL que se ejecutan en orden desde DBeaver, y un orquestador en Python (`etl_oaaf.py`) que los ejecuta todos juntos. Es idempotente: ejecutarlo varias veces da el mismo resultado. Ninguna fila se pierde sin explicación: cada fila leída termina cargada, corregida, asignada a "NO DEFINIDO" o en cuarentena con su motivo.

Paso	Script	Qué hace
1	10_staging.sql	Carga las tres fuentes tal como vienen, todo como texto, con linaje
2	20_perfilado.sql	Mide 34 controles de calidad antes de limpiar y los guarda en `meta.perfil_calidad`
3	30_transformacion.sql	Unifica formatos y códigos, y separa lo irrecuperable en cuarentena
4	40_carga_dimensiones.sql	Carga dim_puesto_control (SCD 1) y dim_viajero (SCD 2)
5	50_carga_hechos.sql	Busca las claves subrogadas y calcula permanencia, plazo y días excedidos
6	60_controles.sql	Concilia leído contra cargado y cierra la ejecución en `meta.ejecucion`

Reglas de calidad. Siguen la distinción de la cátedra entre hecho incompleto y hecho inválido:

Tratamiento	Cuándo	Casos
Cuarentena	Duplicado o fecha imposible	650 duplicados y 30 fechas inválidas en movimientos; 23 alertas duplicadas
Corrección	Forma correcta conocida	Tres formatos de fecha; "CDE" → PC-CDE-PA; E/S/ING/EGR → ENTRADA/SALIDA; nombres de país → código ISO
Miembro -1 (hecho incompleto)	Falta la referencia a una dimensión	180 puestos huérfanos, 295 nacionalidades vacías o inválidas, 356 motivos vacíos, 70 viajeros sin código
Anular la métrica	Medida imposible en un movimiento válido	135 movimientos con minutos de control ⩽ 0 o ⩾ 600

Cada fila en cuarentena tiene un solo motivo, por orden de precedencia (DUPLICADO antes que FECHA_INVALIDA). Eso garantiza que se cumpla **leídas = cargadas + cuarentena**.

Controles de conciliación: los nueve dieron OK.

Control	Resultado
Movimientos: leídos = cargados + cuarentena	51.636 = 50.956 + 680
Alertas: leídas = cargadas + cuarentena	2.022 = 1.999 + 23
Puestos de la fuente = filas de la dimensión	8 = 8
Sin movimientos duplicados en el hecho	0
Una sola versión vigente por viajero	0 viajeros con más de una
Vigencias SCD 2 sin huecos ni solapamientos	0 cortes incorrectos
Cada movimiento apunta a la versión vigente en su fecha	0 fuera de vigencia
ind_alerta coincide con las alertas cargadas	1.966 = 1.966
Permanencias no negativas	0 negativas

6. Análisis OLAP

Cada pregunta quedó como una vista SQL en el esquema `olap` (script `olap/70_consultas_olap.sql`). Las mismas vistas alimentan el tablero, y sus resultados coinciden con los de Power BI.

Pregunta	Operador OLAP	Respuesta
P1 Flujo por puesto	CUBE (puesto × sentido)	El Puente de la Amistad concentra el 27,0 % de los 50.956 movimientos, seguido por el aeropuerto Silvio Pettirossi (20,7 %) y el puente San Roque González de Encarnación (17,8 %)

Pregunta	Operador OLAP	Respuesta
P2 Alertas por franja	Drill-across con GROUPING SETS (puesto × franja)	La madrugada registra 500,3 alertas cada 10.000 movimientos, contra 361,6 a 390,4 en el resto del día. El pico es el puente de Encarnación de madrugada, con 758,8
P3 Tasa de confirmación	ROLLUP (tipo de alerta → puesto)	Documentos robados o extraviados: 59,4 %; orden de captura: 48,3 %; lista de vigilancia nacional: 9,8 %. Promedio general: 30,0 %
P4 Documentos observados	ROLLUP (tipo → estado)	El pasaporte tiene la tasa más alta (166,0 cada 10.000). En todos los tipos predomina el estado vencido
P5 Cruces frecuentes	Función de ventana de 30 días + ROLLUP	515 viajeros con 6 o más cruces en 30 días; 179 en el Puente de la Amistad. El pico mensual es enero de 2026
P6 Permanencia	GROUPING SETS (motivo × categoría)	Promedio 9,8 días y 1,5 % excedidas. Solo exceden los turistas por turismo (3,3 %, 55 días de exceso promedio)
P7 Variación interanual	GROUPING SETS (mes × región, mes × motivo)	Entre noviembre de 2025 y septiembre de 2026, el flujo total creció entre 2,3 % y 14,3 % contra el mismo mes del año anterior, con picos en enero, julio y diciembre

Detalle de P3, tasa de confirmación por tipo de alerta:

Tipo de alerta	Alertas	Confirmadas	Tasa
Documento robado o extraviado	271	161	59,4 %

Tipo de alerta	Alertas	Confirmadas	Tasa
Orden de captura vigente	360	174	48,3 %
Notificación roja	186	82	44,1 %
Inconsistencia documental	217	77	35,5 %
Coincidencia en lista de sanciones	88	18	20,5 %
Permanencia excedida en viaje anterior	21	3	14,3 %
Patrón de viaje irregular	87	10	11,5 %
Lista de vigilancia nacional	769	75	9,8 %

La lista de vigilancia nacional genera el 38 % de todas las alertas (769 de 1.999), pero se confirma en menos de una de cada diez. Es el principal candidato para revisar sus criterios o bajar su prioridad de inspección.

Verificación con el filtro del tablero. Filtrando por Puente de la Amistad, Power BI muestra 594 alertas cada 10.000 movimientos de madrugada, el mismo valor que la vista OLAP (593,9).

7. Tablero en Power BI

El tablero (`powerbi/tablero_oaaf_monitoreo.pbix`) está pensado para los analistas y jefes de puesto: cada gráfico tiene como título la pregunta que responde y debajo una frase que explica cómo leerlo. Usa un estilo de centro de monitoreo, con fondo oscuro y el hallazgo principal de cada gráfico destacado en color.

Página	Contenido
Flujo y alertas	Filtro por puesto, 4 indicadores (movimientos, permanencia promedio, alertas, tasa de confirmación), mapa de los puestos con burbujas según el flujo, y los gráficos de P1 a P4
Viajeros y tendencias	Evolución mensual por región de origen (P7), tabla de permanencia por motivo (P6) y viajeros con cruce frecuente por mes (P5)

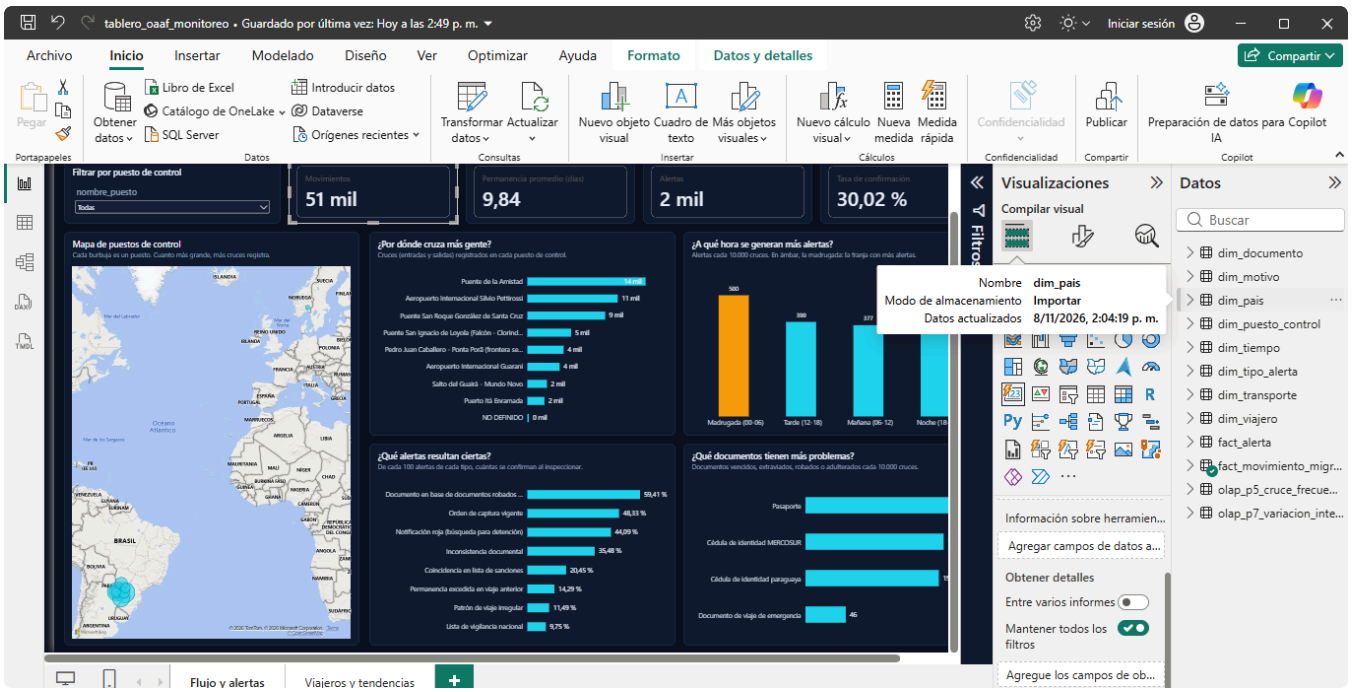


Figura 2. Página "Flujo y alertas" del tablero en Power BI.

Modelo en Power BI. Se importó el esquema estrella exportado desde DuckDB a CSV (script `powerbi/80_exportar_powerbi.sql`) y se recrearon sus 13 relaciones, todas de muchos a uno desde los hechos hacia las dimensiones. Las dos tablas de hechos no se relacionan entre sí: se cruzan a través de las dimensiones compartidas.

Medidas DAX:

Medida	Fórmula (resumida)
Movimientos	SUM(cantidad_movimientos)
% del total nacional	DIVIDE([Movimientos], CALCULATE([Movimientos], REMOVEFILTERS(dim_puesto_control)))
Permanencia promedio (días)	AVERAGE(dias_permanencia)
% permanencias excedidas	DIVIDE(SUM(ind_permanencia_excedida), COUNT(dias_permanencia))
Documentos observados	CALCULATE([Movimientos], dim_documento[es_observado] = TRUE())
Observados cada 10k	DIVIDE([Documentos observados], [Movimientos]) × 10.000

Medida	Fórmula (resumida)
Alertas	SUM(cantidad_alertas)
Alertas cada 10k movimientos	DIVIDE([Alertas], [Movimientos]) × 10.000
Alertas confirmadas / Rechazos de ingreso	SUM(ind_confirmada) / SUM(ind_rechazo_ingreso)
Tasa de confirmación / Tasa de rechazo	DIVIDE(confirmadas o rechazos, [Alertas])

Alertas cada 10k movimientos es el drill-across hecho en DAX: divide una medida de fact_alerta por una de fact_movimiento_migratorio. Funciona porque ambos hechos comparten las dimensiones de tiempo y puesto, y el filtro se aplica a los dos a la vez.

Las tasas se calculan siempre desde numerador y denominador, nunca sumando porcentajes, porque son medidas no aditivas.

8. Limitaciones y criterio ético

Limitaciones:

- **Datos sintéticos.** Los patrones encontrados reflejan los supuestos del generador (estacionalidad, perfiles de viajero, probabilidades de alerta). Sirven para demostrar el Datawarehouse, no para sacar conclusiones sobre fronteras reales.
- **Efecto de inicio del periodo.** Los datos empiezan el 01/10/2024, así que en octubre de 2024 faltan las salidas y los regresos de viajes iniciados antes. Por eso la variación interanual de octubre de 2025 (+31 %) está inflada y no es crecimiento real, y en ese mes hay pocos viajeros frecuentes detectados (P5). Desde noviembre las comparaciones son válidas.
- **Regiones con poco volumen.** Las variaciones interanuales de África, Oceanía y otras regiones con pocos movimientos son muy sensibles: de 1 a 6 movimientos da +500 %. Conviene leerlas como cantidades, no como porcentajes.
- **Permanencia.** Se calcula solo cuando la SALIDA de un extranjero sigue a su ENTRADA. Quedan sin permanencia los viajeros que seguían en el país al cierre del periodo.
- **Agregados de P5 por puesto.** En el tablero, P5 se muestra por mes; el total por puesto (179 en el Puente de la Amistad) sale de la vista SQL, porque sumar meses contaría dos veces a un viajero frecuente en varios meses.

Criterio ético:

- La probabilidad de alerta del dataset depende solo del estado del documento, de la conducta de viaje y de un componente aleatorio de listas de vigilancia. **Nunca de la nacionalidad**, que se usa solo como dimensión descriptiva.
- Los viajeros se identifican con un código seudónimo. No hay nombres ni números de documento.
- Ningún indicador ni gráfico mide riesgo por país de origen.

9. Conclusiones y trabajo futuro

El Datawarehouse cumple el alcance definido en el acta: integra tres fuentes heterogéneas, conserva la historia de los viajeros, explica cada fila que entra o se rechaza y responde las siete preguntas de negocio, con resultados que coinciden entre SQL y Power BI.

Conclusiones para la OAAF:

1. **Personal de madrugada.** Los pasos terrestres generan muchas más alertas de madrugada que en el resto del día. Reforzar ese turno, sobre todo en Encarnación y el Puente de la Amistad, es la decisión con más respaldo en los datos.
2. **Prioridad de inspección.** Las alertas documentales y las órdenes de captura se confirman en la mitad o más de los casos. La lista de vigilancia nacional produce el 38 % de las alertas y casi nunca se confirma: revisar sus criterios liberaría tiempo de inspección.
3. **Seguimiento de viajeros.** 515 viajeros con cruces muy frecuentes y un 3,3 % de turistas que exceden su plazo son grupos concretos y acotados para el seguimiento del área de análisis.

Lecciones del proceso:

- Separar staging, transformación y carga permitió encontrar y corregir errores por partes, como el conteo de la dotación vacía del Excel.
- Los controles de conciliación y el miembro "NO DEFINIDO" hacen que ningún dato se pierda en silencio.
- Comparar los resultados de SQL con los de Power BI fue la mejor forma de validar el modelo de punta a punta.

Trabajo futuro:

- Cargas incrementales diarias en lugar de la carga completa, con el SCD tipo 2 actualizándose por diferencias.

- Programar el orquestador de Python para que se ejecute automáticamente.
- Agregar al tablero una página de calidad de datos con el perfilado y la cuarentena de cada ejecución.
- Incorporar fuentes reales, si la organización existiera, manteniendo el criterio ético.

Anexo: repositorio y reproducción

Todo el proyecto está versionado en github.com/EricaBordon/datawarehouse-oaaf, con un commit por etapa (modelo, ETL, OLAP, tablero). La base `.duckdb` no se versiona: se reconstruye con los scripts.

Carpeta o archivo	Contenido
`01_ddl_dw_oaaf.sql` a `03_prueba_modelo.sql`	Modelo dimensional, carga de dimensiones estáticas y prueba del modelo
`fuentes/`	CSV de movimientos, JSON de alertas, Excel de puestos y anexo `defectos_inyectados.md`
`generador/generar_datos_oaaf.py`	Generador determinista de las fuentes (semilla 22891)
`etl/`	Los seis scripts del ETL y el orquestador `etl_oaaf.py`
`olap/70_consultas_olap.sql`	Vistas OLAP de P1 a P7
`powerbi/`	Exportación a CSV y tablero `tablero_oaaf_monitoreo.pbix`
`docs/`	Acta de alcance, diagramas, matriz de bus, diccionario de datos e informes de avance

Cómo reproducir el proyecto:

1. En DBeaver, crear una conexión DuckDB a un archivo nuevo, por ejemplo `C:/DW_OAAF/dw_oaaf.duckdb`.
2. Ejecutar `01_ddl_dw_oaaf.sql` y `02_carga_dim_tiempo_y_catalogos.sql`.
3. Ejecutar el ETL: los scripts de `etl/` en orden (10 a 60), o `python etl/etl_oaaf.py` con DBeaver desconectado.

4. Ejecutar `olap/70_consultas_olap.sql` para crear las vistas.
5. Crear la carpeta `powerbi/datos` y ejecutar `powerbi/80_exportar_powerbi.sql`.
6. Abrir `powerbi/tablero_oaaf_monitoreo.pbix`. Para ver el mapa, activar en Power BI: Archivo → Opciones → Seguridad → "Usar objetos visuales de Mapa y Mapa coroplético".