Informe técnico de avance H2 — Datawarehouse OAAF

Nov 8, 2026 · @Érica Bordón

Universidad del Norte · Ingeniería Informática · 8.º semestre · Cátedra Datawarehouse (22891)

Datawarehouse para el análisis de riesgos en los movimientos migratorios de los puestos de control de Paraguay

Dato	Información
Organización	Oficina de Análisis Antiterrorista de Fronteras (OAAF), ficticia
Asignatura	Datawarehouse (22891)
Docente	Lic. Walter Romero
Estudiante	Érica Bordón
Fecha de hito	27 de octubre de 2026
Alcance	H2: modelo dimensional, DDL en DuckDB, carga de dimensiones estáticas, preparación de las fuentes y carga inicial en staging

1. Introducción y contexto del negocio

La OAAF es una oficina pública ficticia que analiza los movimientos migratorios de 8 puestos de control de Paraguay para detectar riesgos asociados a terrorismo y delitos transnacionales. Cuenta con unos 40 funcionarios: una sede central en Asunción con el área de análisis y equipos destacados en puestos aéreos, terrestres y fluviales, como el aeropuerto de Luque, el Puente de la Amistad en Ciudad del Este y el puente San Roque González en Encarnación. Los nombres de los puestos son reales y se usan solo como catálogo; todos los movimientos, personas y alertas son sintéticos.

Hoy la OAAF no sabe dónde ni cuándo se concentran las alertas, ni cuántas terminan en un hallazgo real. Los registros de cruce, las alertas y los resultados de inspección están en sistemas separados y se cruzan a mano en planillas. El Datawarehouse integra esas

fuentes para mejorar tres decisiones: la asignación de personal por puesto y franja horaria, la priorización de la inspección secundaria y el seguimiento de patrones de viaje irregulares y permanencias excedidas.

Rol asumido: analista de datos del área de análisis de la OAAF. Sponsor: la jefatura de la OAAF. Usuarios clave: los analistas de riesgo y los jefes de equipo de cada puesto.

Criterio ético: el riesgo se mide por alertas, estado del documento y conducta de viaje, nunca por la nacionalidad, que se usa solo como dimensión descriptiva. Los viajeros se identifican con un código seudónimo, sin nombres ni números de documento.

2. Objetivos y preguntas de negocio

Objetivo general: diseñar e implementar un Datawarehouse dimensional que integre movimientos migratorios, alertas y catálogo de puestos de la OAAF para apoyar sus decisiones operativas.

Objetivos específicos del avance H2:

1. Diseñar el modelo dimensional (constelación de dos hechos con dimensiones conformadas).
2. Documentarlo con diagrama, matriz de bus y diccionario de datos.
3. Implementar el DDL en DuckDB, con claves, restricciones y miembro "NO DEFINIDO".
4. Cargar las dimensiones estáticas y probar el modelo, incluido el SCD tipo 2.
5. Preparar las tres fuentes heterogéneas y cargarlas en staging, verificando sus conteos.

Preguntas de negocio:

N.º	Pregunta	Indicador	Analizado por
P1	¿Qué puestos concentran el flujo migratorio por mes y sentido?	Movimientos y % sobre el total nacional	Puesto, tiempo, sentido
P2	¿En qué puestos y franjas horarias se generan más alertas?	Alertas cada 10.000 movimientos	Puesto, franja horaria, tipo de alerta

N.º	Pregunta	Indicador	Analizado por
P3	¿Qué tipos de alerta terminan con más frecuencia en confirmación o rechazo de ingreso?	Tasa de confirmación %	Tipo de alerta, puesto, tiempo
P4	¿Qué tipos de documento presentan más observaciones?	Documentos observados cada 10.000 movimientos	Tipo de documento, puesto, tiempo
P5	¿Cuántos viajeros cruzan con mucha frecuencia y en qué puestos?	Viajeros con 6 o más cruces en 30 días	Viajero, puesto, tiempo
P6	¿Cuál es la permanencia promedio y cuántas exceden el plazo?	Permanencia promedio (días); % excedidas	Motivo, categoría migratoria, tiempo
P7	¿Cómo varía el flujo por región de origen y motivo a lo largo del año?	Movimientos por mes; variación % interanual	País/región, motivo, tiempo

P2, P3 y P4 cruzan los dos hechos mediante dimensiones conformadas (drill-across).

3. Fuentes y preparación del dataset

El proyecto usa tres fuentes heterogéneas en tres formatos distintos, con 53.667 registros en total y una tabla de hechos principal de 50.986 movimientos únicos (mínimo exigido: 5.000).

Fuente	Formato	Contenido	Origen	Registros
Movimientos migratorios	CSV (exportación del sistema de control fronterizo)	Fecha y hora, puesto, sentido, código de viajero, nacionalidad, documento, motivo, transporte, plazo, minutos de control	Sintético, generado con Python	51.636

Fuente	Formato	Contenido	Origen	Registros
Alertas e inspección	JSON anidado (servicio de alertas)	Alerta, tipo y nivel, documento, resultado de la inspección secundaria	Sintético, generado con Python	2.022
Catálogo de puestos	Planilla Excel (.xlsx)	Puesto, tipo, ciudad, departamento, país limítrofe, dotación, coordenadas	Nombres reales, datos operativos simulados	9

Las fuentes se generan con el script `generar_datos_oaaf.py`, con semilla fija 22891: cada ejecución produce exactamente los mismos archivos. Cubren 24 meses, de octubre de 2024 a septiembre de 2026, con 11.650 viajeros seudónimos.

El generador simula tres perfiles de viajero: fronterizos que cruzan muchas veces, viajeros ocasionales y migrantes que cambian de categoría (turista a residente). Incluye estacionalidad (verano, julio y fiestas), un crecimiento interanual cercano al 8 % y horarios distintos para puestos aéreos y terrestres. La probabilidad de alerta depende solo del estado del documento, de la conducta de viaje y de un componente aleatorio de listas de vigilancia; nunca de la nacionalidad.

Imperfecciones deliberadas (detalle completo en el anexo `defectos_inyectados.md`):

- 650 filas duplicadas en el CSV y 23 alertas duplicadas en el JSON.
- Fechas en tres formatos (ISO, ISO con "T" y dd/mm/aaaa) y 30 fechas imposibles o vacías.
- Puestos escritos como texto libre ("CDE", "Ciudad del Este", " ciudad del este ") y 180 códigos huérfanos.
- Sentido con variantes (E, S, ING, EGR), nacionalidades vacías o escritas como nombre, motivos vacíos.
- Minutos de control vacíos, negativos o fuera de rango (600 minutos o más).
- En el Excel: ciudad abreviada, departamento sin tilde, coma decimal y un puesto repetido con una corrección posterior.

4. Arquitectura y modelo dimensional

El modelo es una constelación: dos tablas de hechos que comparten cinco dimensiones conformadas, sobre DuckDB 1.5 con DBeaver como cliente SQL y Python para generar los datos. La base `dw_oaaf.duckdb` tiene tres esquemas: `stg` (recepción de fuentes crudas), `dw` (modelo dimensional) y `meta` (linaje y control de ejecuciones).

4.1 Dimensiones y hechos

Tipo	Tabla	Propósito
Hechos (principal)	fact_movimiento_migratorio	Cantidad, minutos de control, plazo, días de permanencia, días excedidos, indicadores de permanencia excedida y de alerta
Hechos (secundaria)	fact_alerta	Cantidad de alertas, indicadores de inspección secundaria, confirmación y rechazo, minutos de inspección
Dimensión conformada	dim_tiempo	Fecha y hora, franja horaria, día de semana, feriados, mes, trimestre, año
Dimensión conformada	dim_puesto_control	Puesto, tipo, ciudad, departamento, país limítrofe, dotación, coordenadas
Dimensión conformada	dim_viajero	Código seudónimo, rango etario, categoría migratoria con historial
Dimensión conformada	dim_pais	Nacionalidad, región, pertenencia a MERCOSUR, país limítrofe
Dimensión conformada	dim_documento	Tipo y estado del documento (vigente, vencido, extraviado, robado, adulterado)
Dimensión exclusiva	dim_motivo	Turismo, negocios, tránsito, trabajo, estudio, residencia
Dimensión exclusiva	dim_transporte	Aéreo, terrestre particular, ómnibus, fluvial, a pie
Dimensión exclusiva	dim_tipo_alerta	Tipo de alerta, nivel de riesgo, organismo emisor

4.2 Grano y cambios históricos

- **fact_movimiento_migratorio:** una fila por movimiento: un viajero, en un puesto, en un sentido, en una fecha y hora. La clave del sistema fuente queda como dimensión degenerada (`dd_id_movimiento`) y es la clave primaria, lo que impide duplicados.

- **fact_alerta:** una fila por alerta emitida, con el movimiento que la disparó como dimensión degenerada.
- **dim_tiempo a nivel hora:** la clave `sk_tiempo` sigue el formato AAAAMMDDHH. Así se analizan franjas horarias (P2) sin una dimensión aparte.
- **dim_viajero, SCD tipo 2:** cada cambio de categoría migratoria (turista, residente temporal, residente permanente) crea una versión nueva con fechas de vigencia. Cada movimiento apunta a la versión vigente en su fecha, lo que permite medir la permanencia excedida según la categoría de cada cruce (P6). La lógica de cierre y apertura de versiones está implementada y probada.
- **dim_puesto_control, SCD tipo 1:** las correcciones de ciudad o departamento sobrescriben el valor anterior, porque son errores de carga.
- **Miembro "NO DEFINIDO":** cada dimensión tiene la fila `sk = -1` para códigos huérfanos o nulos. Las claves foráneas de los hechos nunca quedan en NULL.
- **Sentido (entrada o salida):** queda como atributo degenerado del hecho, porque solo tiene dos valores.

4.3 Diagrama del modelo

Las cinco dimensiones del centro (tiempo, puesto, viajero, país y documento) se conectan con los dos hechos; motivo y transporte solo describen movimientos, y tipo de alerta solo describe alertas.

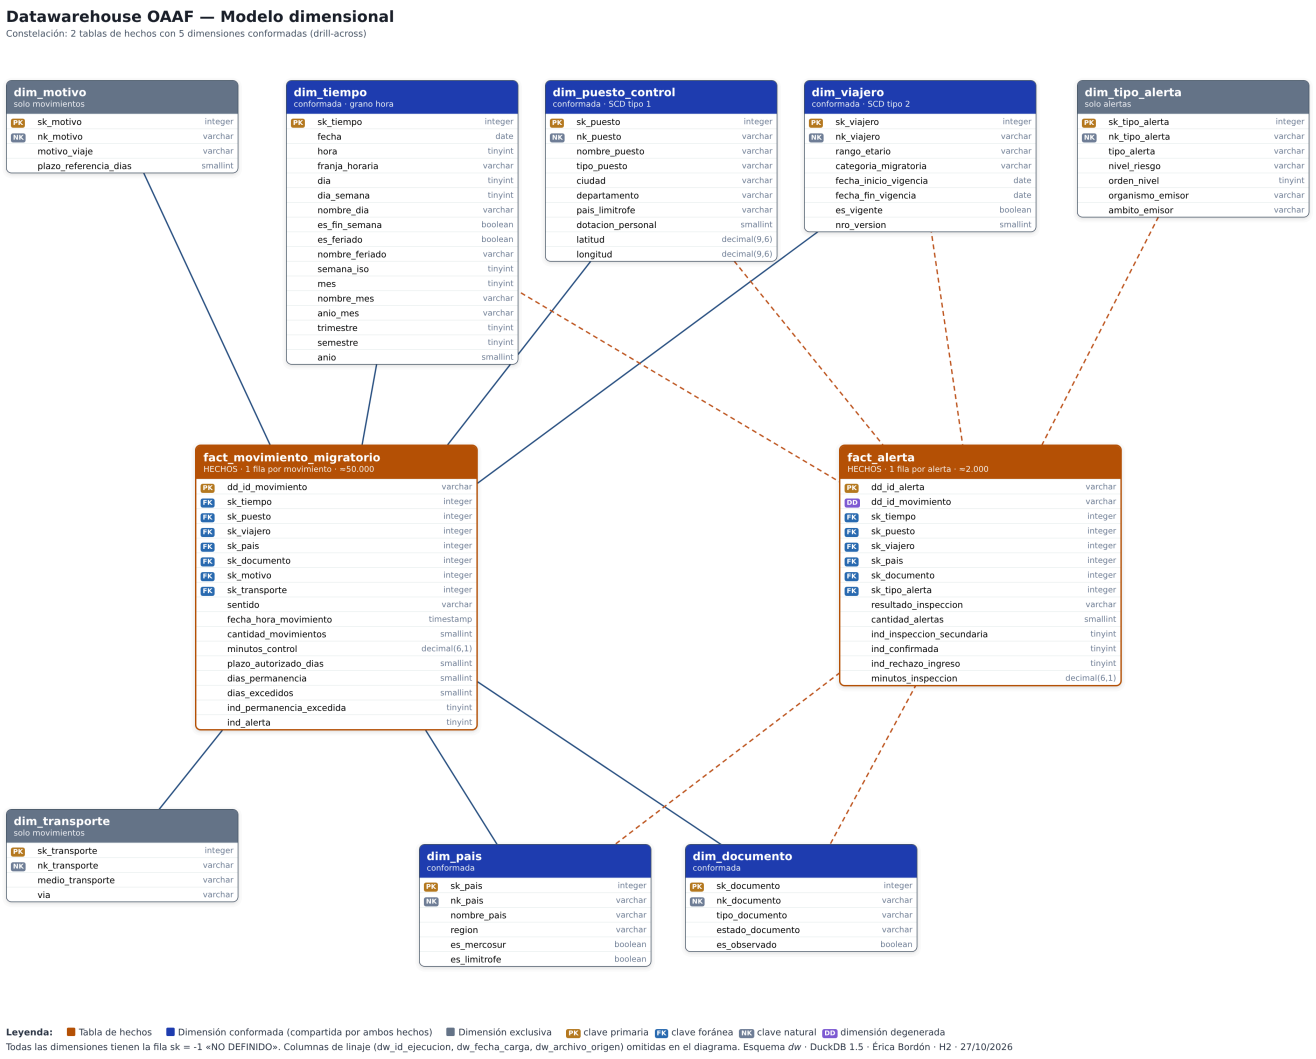


Figura 1. Modelo dimensional del Datawarehouse OAAF. Naranja: tablas de hechos; azul: dimensiones conformadas; gris: dimensiones exclusivas.

4.4 Matriz de bus

Proceso de negocio	Tiempo	Puesto	Viajero	País	Documento	Motivo	Transporte	Tipo de alerta
Movimientos migratorios	X	X	X	X	X	X	X	
Alertas e inspección	X	X	X	X	X			X

El diccionario de datos completo, columna por columna, está en `Matriz_Bus_y_Diccionario_DW_OAAF.xlsx`.

5. Implementación SQL y validación

El modelo se implementó con cuatro scripts idempotentes: se pueden ejecutar varias veces y dejan siempre el mismo resultado. Todos se ejecutaron en DuckDB 1.5 desde DBeaver sin errores.

Script	Qué hace
`01_ddl_dw_oaaf.sql`	Crea los esquemas `stg`, `dw` y `meta`, las 10 tablas con claves primarias, claves foráneas y restricciones CHECK, y la fila `-1` en cada dimensión
`02_carga_dim_tiempo_y_catalogos.sql`	Genera dim_tiempo (una fila por hora de 2024 a 2026, con feriados de Paraguay) y carga las dimensiones estáticas
`03_prueba_modelo.sql`	Dentro de una transacción prueba el SCD tipo 1, el SCD tipo 2, la carga de hechos y una consulta drill-across; termina con ROLLBACK
`etl/10_staging.sql`	Carga las tres fuentes en staging tal como vienen, todo como texto, con columnas de linaje y registro en `meta.ejecucion`

5.1 Validación de la estructura y las dimensiones estáticas

Tabla	Esperado	Observado	Estado
Tablas en el esquema dw	10	10	OK
dw.dim_tiempo	26.305	26.305	OK
dw.dim_documento	21	21	OK
dw.dim_motivo	7	7	OK
dw.dim_transporte	6	6	OK
dw.dim_tipo_alerta	9	9	OK
dw.dim_pais	23	23	OK

Los conteos incluyen la fila `-1` "NO DEFINIDO". dim_tiempo tiene 26.304 horas (3 años por 24 horas) más esa fila.

5.2 Prueba del modelo

El script 03 terminó sin errores. El viajero de prueba quedó con dos versiones (turista hasta el 28/02/2025, residente temporal desde el 01/03/2025), cada movimiento tomó la versión vigente en su fecha y la consulta drill-across devolvió alertas cada 10.000 movimientos por puesto y franja. Un INSERT con un puesto inexistente fue rechazado por la clave foránea, como se esperaba.

5.3 Validación de la carga en staging

Tabla de staging	Esperado	Observado	Estado
stg.stg_movimiento	51.636	51.636	OK
stg.stg_alerta	2.022	2.022	OK
stg.stg_puesto	9	9	OK
Total	53.667	53.667	OK

La igualdad de conteos verifica la recepción, no la calidad: staging guarda los datos tal como vienen, con sus defectos. La limpieza, la cuarentena y la carga dimensional corresponden al hito siguiente.

6. Evidencias y trazabilidad

Cada carga deja su rastro: las tablas de staging y del modelo llevan tres columnas de linaje (`dw_id_ejecucion`, `dw_fecha_carga` y `dw_archivo_origen`), y cada ejecución queda registrada en `meta.ejecucion` con su inicio, fin, filas leídas y estado.

Archivo	Contenido
`diagrama_estrella_dw_oaaf.pdf` / `.png`	Diagrama del modelo dimensional
`diagrama_implementado_dbeaver.png`	Diagrama ER generado por DBeaver desde la base real, con las claves foráneas implementadas

Archivo	Contenido
`Matriz_Bus_y_Diccionario_DW_OAAF.xlsx`	Matriz de bus y diccionario de datos de las 10 tablas
`01_ddl_dw_oaaf.sql`, `02_carga_dim_tiempo_y_catalogos.sql`, `03_prueba_modelo.sql`	DDL, carga de dimensiones estáticas y prueba del modelo
`generador/generar_datos_oaaf.py`	Generador determinista de las tres fuentes (semilla 22891)
`fuentes/`	CSV de movimientos, JSON de alertas, Excel de puestos y su copia CSV de contingencia
`fuentes/defectos_inyectados.md`	Anexo con las imperfecciones deliberadas y sus cantidades
`etl/10_staging.sql`	Carga inicial en staging
`dw_oaaf.duckdb`	Base de ejecución local (se reconstruye con los scripts)

7. Estado del proyecto y próximos pasos

Componente	Estado H2
Modelo dimensional y DDL	Implementados y probados
Diagrama, matriz de bus y diccionario de datos	Elaborados
dim_tiempo y dimensiones estáticas	Cargadas y verificadas
Lógica SCD tipo 1 y tipo 2	Implementada y probada con datos de ejemplo
Fuentes heterogéneas (CSV, JSON, Excel)	Generadas, con defectos documentados
Carga inicial en staging	Realizada y verificada por conteo

Próximos pasos:

1. **ETL completo:** perfilado de calidad, limpieza y estandarización, cuarentena de filas irrecuperables, carga de dim_puesto_control (SCD 1) y dim_viajero (SCD 2), carga de los dos hechos con sus métricas derivadas y controles de conciliación.
2. **Consultas OLAP** que respondan P1 a P7 con GROUPING SETS, CUBE y ROLLUP, incluido el drill-across entre movimientos y alertas.
3. **Tablero en Power BI Desktop** para los analistas de riesgo y los jefes de equipo de cada puesto.

8. Conclusión

El avance H2 dejó implementado en DuckDB el modelo dimensional del Datawarehouse de la OAAF: dos tablas de hechos y ocho dimensiones, cinco de ellas conformadas, con integridad referencial, miembro "NO DEFINIDO" e historial SCD tipo 2 probado. Además se recibieron en staging, con conteos verificados, 53.667 registros de tres fuentes heterogéneas en CSV, JSON y Excel. El modelo ya permite el drill-across que necesitan las preguntas P2, P3 y P4, y deja todo listo para construir el ETL completo.